

Bilişsel Performans Skoru Analizi

Veri setinin yapısını, risklerini ve modelleme öncesi dikkat edilmesi gereken noktaları özetleyen keşifsel veri analizi raporu.

EĞİTİM SETİ TEST SETİ DEĞİŞKEN SAYISI PROBLEM TİPİ

56.000 satır 24.000 satır 23 özellik Regresyon

BÖLÜM 01

Veri Seti Genel Yapısı

Değişken tipleri, sayısal ve kategorik dağılım.

16

SAYISAL DEĞİŞKEN

int64 + float64

7

KATEGORİK DEĞİŞKEN

object tipi

6

EKSİK DEĞERLİ SÜTUN

%1.96 – %3.51

0–10

HEDEF ARALIĞI

Süreklili sayısal

Değişken	Tip	Açıklama	Not
stres_skoru	float	Stres düzeyi (sayısal skor)	En güçlü özellik
rem_yuzdesi	float	REM uykusunun toplam uyku içindeki oranı	Güçlü pozitif etki
gunluk_calisma_saati	float	Günlük çalışma süresi	Negatif etki

derin_uyku_yuzdesi	float	Derin uyku oranı	Pozitif etki
ruh_sagligi_durumu	object	Sağlıklı / Anksiyete / Depresyon	Sınıf dengesizliği var
kronotip	object	Sabah / Gece / Nötr insanı	%3.51 eksik
meslek	object	11 farklı meslek grubu	%2.46 eksik
ulke	object	15 farklı ülke	Nadir kategoriler var
oda_sicakligi_celsius	float	Uyku ortamı sıcaklığı	Korelasyon ~0
hafta_sonu_uyku_farki_saat	float	Hafta sonu uyku değişimi	Korelasyon ~0

BÖLÜM 02

Hedef Değişken Analizi

bişisel_performans_skoru — 0 ile 10 arasında sürekli sayısal değer.

5.91

Ortalama

6.03

Medyan

2.23

Std Sapma

0.00

Minimum

10.00

Maksimum

4.40 – 7.57

IQR Aralığı

✓ **Dağılım normale yakın.** Ortalama (5.91) ve medyan (6.03) birbirine çok yakın — simetrik bir dağılım. Logaritmik dönüşüme gerek yoktur.

⚠ **10 değerinde yığılma.** Histogramda tam 10 değerinde anormal bir tepe var. Bu değerlerin yapay olarak sabitlenmiş olabileceği düşünülmelidir. Tahminler 0–10 arasına klamp edilmelidir.

Eksik Değer Analizi

6 sütunda eksik değer tespit edilmiştir. Oranlar %1.96 – %3.51 arasındadır.

kronotip		%3.51Kategorik → "Bilinmiyor" ekle
vucut_kitle_indeksi		%3.13Sayısal → medyan ile doldur
stres_skoru		%3.06△ Hedefle güçlü ilişkili! Medyan ile doldur
uyku_onesi_kafein_mg		%2.61Sayısal → medyan ile doldur
meslek		%2.46Kategorik → "Bilinmiyor" ekle
ruh_sagligi_durumu		%1.96△ Hedefle güçlü ilişkili! "Bilinmiyor" ekle

△ **stres_skoru ve ruh_sagligi_durumu kritik.** Bu iki değişken hedefle en güçlü ilişkiye sahip olup aynı zamanda eksik değer içermektedir. Eksiklerin rastgele mi (MCAR) yoksa sistematik mi (MAR) olduğu bilinmiyor — basit medyan doldurma yapılacak ancak dikkatli yorumlanmalıdır.

Sayısal Değişkenler — Korelasyon

Pearson korelasyonu. Mavi: pozitif etki, kırmızı: negatif etki.

stres_skoru		-0.587	Çok Güçlü
rem_yuzdesi		+0.443	Güçlü
gunluk_calisma_saati		-0.342	Orta-Güçlü
derin_uyku_yuzdesi		+0.280	Orta
gecelik_uyanma_sayisi		-0.270	Orta
uykuya_dalma_suresi_dk		-0.207	Orta-Zayıf
gunluk_adim_sayisi		+0.134	Zayıf
dinlenik_nabiz_bpm		-0.089	Çok Zayıf
oda_sicakligi_celsius		-0.012	Anlamsız
hafta_sonu_uyku_farki_saat		-0.002	Anlamsız

✓ **Feature Engineering fırsatı:** Tek başına zayıf olan oda_sicakligi ve hafta_sonu_uyku_farki değişkenleri, diğer uyku değişkenleriyle çarpımsal kombinasyonlar oluşturularak anlam kazanabilir.

Kategorik Değişken Analizi

Her kategorik değişkenin veri setinde ne anlama geldiği, hangi değerleri aldığı ve bilişsel performans üzerindeki etkisi.

Değişken	Ne anlama gelir?	Hangi değerleri alır?	Veri setinde ne görüyoruz?	Bilişsel performansa etkisi	Risk
ruh_sagligi_durumu	Kişinin zihinsel sağlık durumu. Anksiyete kaygı bozukluğu, depresyon ise ruh hali bozukluğu anlamına gelir.	Sağlıklı / Anksiyete / Depresyon / Anksiyete ve depresyon	56.000 kişinin ~38.000'i "Sağlıklı". "Anksiyete ve depresyon" birlikte çok nadir görülüyor.	En güçlü kategorik değişken. Sağlıklı bireyler belirgin şekilde daha yüksek skor alıyor. Anksiyete+depresyon grubunun skoru en düşük.	Yüksek
gun_tipi	Ölçümün alındığı günün hafta içi mi hafta sonu mu olduğu.	Hafta içi / Hafta sonu	Hafta içi kayıtlar hafta sonunun yaklaşık 3 katı. Veri dengesiz dağılmış.	Hafta sonu bilişsel performans belirgin şekilde daha yüksek. Muhtemelen dinlenme ve stres azlığından kaynaklanıyor.	Orta
kronotip	Kişinin biyolojik uyku ritmi. Sabah insanı erken uyur/kalkar, gece insanı geç uyur/kalkar.	Sabah insanı / Gece insanı / Nötr	Nötr tipler en kalabalık grup. Sabah insanları en az. %3.51 eksik değer var.	Sabah insanları hafif daha yüksek skor alıyor ancak gruplar arası fark küçük. Tek başına belirleyici değil.	Düşük
mevsim	Ölçümün alındığı mevsim. İki geniş grupta toplanmış.	İlkbahar–Yaz / Sonbahar–Kış	Her iki grup neredeyse eşit sayıda kayıt içeriyor. Dağılım dengeli.	İlkbahar–Yaz grubunda performans biraz daha yüksek. Fark küçük ama tutarlı. Muhtemelen gün ışığı ve aktivite farkından kaynaklanıyor.	Düşük
ulke	Katılımcının yaşadığı ülke.	15 farklı ülke (İngiltere, Çin, Amerika, Fransa vb.)	İngiltere ve Çin baskın. İsveç, Spain, Netherlands gibi ülkeler çok az kayıt içeriyor. Bu nadir ülkeler model için sorun çıkarabilir.	Ülkeler arasında kültürel ve yaşam tarzı farklılıkları performansı etkileyebilir. Ancak nadir ülkelerin az verisi güvenilir öğrenmeyi zorlaştırır.	Orta
meslek	Kişinin meslek grubu.	11 farklı meslek (Sağlık Personeli, Mühendis, Öğrenci, Yönetici vb.)	Sağlık Personeli en kalabalık grup. "Lawyer" İngilizce kalmış, veri tutarsızlığına işaret ediyor. %2.46 eksik.	Meslekler arasında çalışma saati ve stres düzeyi farklı olduğundan dolayı etkisi var. Tek başına orta düzeyde belirleyici.	Düşük
cinsiyet	Kişinin cinsiyeti.	Kadın / Erkek	Kadın ve erkek neredeyse eşit sayıda. Dağılım dengeli.	İki grup arasında bilişsel performans açısından anlamlı bir fark gözlemlenmiyor. Modele	Çok Düşük

⚠ **ruh_sagligi_durumu sınıf dengesizliği kritik!** "Sağlıklı" kategorisi ~38.000 gözlem ile baskın. "Anksiyete ve depresyon" grubu çok az. Model bu azınlık grubu yeterince öğrenemeyebilir. Encoding yapılırken bu dengesizlik göz önünde bulundurulmalıdır.

⚠ **"Lawyer" tutarsızlığı.** meslek sütununda diğer tüm değerler Türkçe iken "Lawyer" İngilizce kalmış. Bu bir veri giriş hatasına işaret ediyor. Encoding öncesinde standardize edilmelidir.

BÖLÜM 06

Aykırı Değer Analizi

IQR yöntemi ile tespit edilen aykırı değerler ve önerilen işlemler.

Değişken	Aykırı %	Gerçek Min	Gerçek Max	IQR Alt Sınır	IQR Üst Sınır	Risk
uyku_onesi_kafein_mg	%6.00	0	400	-115.5 (teorik)	192.5	Düşük
uyku_onesi_ekran_suresi_dk	%5.88	2	180	-51.0 (teorik)	165.0	Düşük
stres_skoru	%1.76	1.0	10.0	1.65	9.95	Düşük
uykuya_dalma_suresi_dk	%0.95	1	58	-2.5 (teorik)	41.5	Düşük
rem_yuzdesi	%0.75	10.0	30.0	10.98	29.57	Düşük
dinlenik_nabiz_bpm	%0.54	45	97	47.0	87.0	Düşük
hafta_sonu_uyku_farki_saat	—	-1.0 (anlamlı)	3.0	-0.97	3.37	Yok
gecelik_uyanma_sayisi	%0.00	0	8	—	9.5	Yok
oda_sicakligi_celsius	%0.00	15.0	28.0	12.36	28.62	Yok
yas	%0.33	18	69	—	66.0	Düşük
vucut_kitle_indeksi	%0.31	16.0	45.0	13.96	38.54	Düşük
gunluk_adim_sayisi	%0.30	500	20000	—	17127	Düşük

✓ **Veri setinde sorunlu değer bulunmamaktadır.** IQR yöntemi bazı sütunlar için teorik alt sınırları negatif hesaplamıştı. Ancak gerçek min/max değerleri incelendiğinde tüm değerlerin biyolojik ve fiziksel olarak mümkün aralıklarda olduğu görülmüştür.

✓ **hafta_sonu_uyku_farki_saat negatif değerleri normaldir.** Bu sütun hafta sonu ile hafta içi uyku farkını gösterir. Negatif değer "hafta sonu daha az uyumuş" anlamına gelir — fiziksel olarak mümkün ve anlamlıdır. Dokunulmayacak.

✓ **Tree-based modeller aykırı değerlere dayanıklıdır.** Random Forest ve Gradient Boosting gibi algoritmalar üst sınırı aşan aykırı değerlerden genellikle etkilenmez. Herhangi bir klamp işlemi gerekmemektedir.

Train vs Test Karşılaştırması

İki setin dağılım uyumu — distribution shift riski değerlendirmesi.

Değişken	Train Ort.	Test Ort.	Fark %	Durum
yas	34.71	34.66	%0.15	✓ Uyumlu
rem_yuzdesi	20.23	20.28	%0.24	✓ Uyumlu
stres_skoru	5.74	5.72	%0.35	✓ Uyumlu
gunluk_adim_sayisi	7493	7517	%0.32	✓ Uyumlu
dinlenik_nabiz_bpm	66.60	66.51	%0.13	✓ Uyumlu

✓ **Distribution shift riski yok.** Tüm sayısal değişkenlerde train ve test ortalamaları %1'in altında farklılık göstermektedir. Her iki set aynı popülasyondan geliyor — modelimiz test setine iyi genelleme yapabilir.

Risk Matrisi ve Sonraki Adımlar

EDA boyunca tespit edilen riskler ve modelleme öncesi yapılması gerekenler.

#	Risk / Sorun	Etki	Öncelik
1	ruh_sagligi_durumu sınıf dengesizliği	Yüksek	Yüksek
2	stres_skoru eksik (%3.06) — hedefle güçlü ilişkili	Yüksek	Orta
3	kronotip eksik (%3.51)	Orta	Orta
4	Hedef değişkende 10'da yığılma	Düşük	Düşük
5	ulke — nadir kategoriler (İsveç, Spain vb.)	Düşük	Düşük
6	meslek'te "Lawyer" İngilizce kalmış — veri tutarsızlığı	Düşük	Düşük
7	hafta_sonu_uyku_farki — hedefle anlamsız korelasyon	Düşük	Bilgi

Önerilen Modelleme Akışı

1 **Veri Temizleme:** meslek sütunundaki "Lawyer" değerini "Avukat" olarak standardize et. Veri setinde fiziksel olarak imkansız negatif değer bulunmamaktadır.

2 **Eksik Değer Doldurma:** Medyan ve mod değerleri **sadece train'den hesapla**, aynı değerleri hem train hem test'e uygula. Test'ten hesaplama yapılırsa veri sızıntısı oluşur.

3 **Encoding:** Train + Test birleřtirip OrdinalEncoder uygula. Birleřtirme encoding içindir, model eğitimi sadece train üzerinde yapılır.

4 **Feature Engineering:** Uyku kalite skoru, stres $\times$ uyanma çarpımı, REM $\times$ derin uyku etkileřimi gibi yeni deęişkenler türet.

5 **Modelleme:** HistGradientBoosting, RandomForest, ExtraTrees ile başla. Bu algoritmalar eksik deęerlere ve aykırılara dayanıklıdır.

6 **Deęerlendirme:** 5-Fold Cross Validation ile RMSE ölç, fold bazında kararlılıęı kontrol et.

7 **Ensemble:** Stacking veya aęırlıklı ortalama ile sonuçları birleřtir, tahminleri 0–10 arasına klamp et.